

1. Datos

El dataset consiste en 100 grabaciones de cobranza telefónica (50 humanas y 50 de IA) en formato WAV mono. Todos los audios comparten un contexto similar: la negociación de una obligación financiera — revisión de saldos, descuentos y cuotas — sobre un canal telefónico, con un pitido que censura nombres propios y entidades por privacidad. Esa censura condiciona el análisis: ninguna variable puede depender de un nombre o de la marca de la empresa que gestiona la cartera.

2. Procesamiento: transcripción y diarización

La transcripción se hizo con **Whisper large-v3** sobre GPU en Google Colab. La diarización — decidir quién habla y cuándo — se hizo con **pyannote.audio**: el modelo segmenta el audio en tramos de voz, calcula un *embedding* por tramo, y agrupa esas huellas por similitud para resolver cuántas personas hablan y a quién pertenece cada tramo. Se forzó la solución a dos hablantes (agente y deudor, siempre presentes en este dominio) y se ajustó la sensibilidad del agrupamiento para no perder intervenciones cortas.

3. Calidad de la medición y exclusiones

Cada audio pasa por dos modelos y cada uno aporta error. El diagnóstico está en los hablantes detectados por llamada, que deberían ser siempre dos:

	1 hablante	2 hablantes	3 etiquetas
Humanos	16 (32 %)	33 (66 %)	1 (2 %)
IA	1 (2 %)	46 (92 %)	3 (6 %)

Se compararon las transcripciones contra los audios reales y se observó lo siguiente:

- Los casos de un solo hablante se debieron mayoritariamente a errores del modelo, y no a llamadas sin conversación. Hubo excepciones de grabaciones sin interlocutor real, que se excluyeron del análisis miden contactabilidad, no gestión..
- Los casos de 3 etiquetas son 2 hablantes más una etiqueta UNKNOWN residual, con menos de 6 s de audio en los cuatro casos.
- El error se concentra en turnos muy breves (<1,5 s, ej. “sí, con ella”): el fragmento de voz es demasiado corto para diferenciarse del hablante vecino con un *embedding* confiable.

4. Asignación de roles: agente vs. deudor

La diarización etiqueta a los hablantes como **SPEAKER_00/SPEAKER_01**, pero esa etiqueta es arbitraria: no indica quién es el agente y quién el deudor, ni significa lo mismo entre una llamada y otra. Para resolverlo sin pagar una API, se usaron dos prompts copiados manualmente a un LLM de chat (GPT 5.6 Luna), disponibles en el repositorio junto al cuaderno de ejecución. El primero se aplicó a las llamadas donde la diarización sí detectó dos (o tres) hablantes: a partir de la apertura de la llamada, el modelo decide cuál etiqueta corresponde al agente y cuál al deudor. El segundo se aplicó a las llamadas donde la diarización colapsó ambas voces en una sola etiqueta: aquí el modelo reconstruye el rol segmento por segmento, usando solo el contenido del texto (quién pregunta vs. quién responde, quién se identifica como empresa vs. quién confirma su propia identidad). En los casos sin evidencia suficiente, el segmento se marca como INCIERTO en vez de forzar una asignación.

5. Preguntas e hipótesis

El análisis responde tres preguntas: **(i)** quién cierra más y mejor, **(ii)** qué conductas explican la diferencia y **(iii)** qué tendría que cambiar para acercar los resultados. De ahí se derivan cuatro hipótesis sobre la *forma* de gestionar, cada una atada a una variable medible de forma determinística sobre tiempos y metadatos:

	Hipótesis	Variable que la contrasta
H1	La IA responde más lento y rompe el ritmo	latencia_agente_med, silencio_pct
H2	La IA sustituye persuasión por presión legal	n_presion_legal
H3	La IA cumple el protocolo de apertura con más consistencia	se_identifica, verifica_identidad
H4	La llamada de IA es estructuralmente más auditable	diarizacion_colapsada

Variables construidas. Cada llamada se resume en una fila con 23 variables: ritmo conversacional (latencias, silencio, turnos, velocidad), reparto de habla, presión/urgencia, protocolo de apertura y calidad de la medición. La unidad de análisis es el **turno** — segmentos consecutivos del mismo rol agrupados — y no el fragmento de Whisper, que parte frases a mitad e infla cualquier conteo.

Decisión de alcance. Se descartaron variables que dependían de detectar palabras sueltas sin verificar el sentido de la frase (empatía verbalizada, permisos, mención de canal de pago): el mismo patrón puede aparecer con un significado distinto al que se busca medir. Esas dimensiones se recuperaron después, mejor medidas, vía etiquetado semántico.

6. Variables semánticas: etiquetado con LLM

Las cuatro hipótesis anteriores describen *cómo* habla cada agente, pero la pregunta central — *quién es más efectivo* — es semántica: exige leer la conversación y juzgar en qué terminó. Con el mismo método usado para los roles, cada llamada se exportó como un guion de texto plano (turnos agrupados, sin marcas de tiempo, que solo añaden ruido a un juicio de sentido) y se etiquetó con un LLM en cinco dimensiones: desenlace de la negociación, tipo de objeción del deudor, si el agente respondió a esa objeción con una concesión concreta, si quedó claro el mecanismo de pago, y tono predominante del agente. El prompt está en el repositorio junto al cuaderno de ejecución.

Dos controles sobre este insumo, por venir de un modelo y no de un cálculo determinístico: el LLM reporta su propia confianza por llamada (que se usa más abajo como prueba de robustez), y se verificó que no haya inventado categorías fuera de las que pedía el prompt.

7. Resultados

Las variables continuas se contrastan con **Mann-Whitney** (no exige normalidad y resiste el outlier de 20 minutos que hay entre las llamadas humanas) y las binarias con la **prueba exacta de Fisher** — exacta y no aproximada, porque varias categorías quedan con muy pocos casos, donde χ^2 no es válido.

Cómo habla cada agente (H1–H4).

	Humanos	IA	<i>p</i>
H1 · Latencia de respuesta del agente (mediana)	0,27 s	1,87 s	<0,001
<i>control: latencia del deudor</i>	0,11 s	0,86 s	<0,001
<i>solo diarización limpia</i>	0,14 s	1,51 s	<0,001
H1 · Silencio dentro de la llamada	16 %	22 %	<0,001
H2 · Llamadas con presión legal o urgencia	33 %	80 %	<0,001
H3 · El agente se identifica en la apertura	60 %	80 %	0,048
H3 · El agente verifica la identidad del interlocutor	27 %	47 %	0,059
H4 · Diarización colapsada (llamada no auditable)	29 %	0 %	<0,001

La latencia del deudor funciona como control: si la lentitud viniera del canal telefónico, ambos lados responderían igual de tarde en las llamadas de IA. La brecha del agente es cuatro veces mayor que la del deudor, así que la demora es del agente. El hallazgo tampoco depende de las llamadas con diarización dudosa: restringido al subconjunto limpio, la mediana de la IA baja de 1,87 s a 1,51 s pero sigue siendo un orden de magnitud superior a la humana. Las dos variables de H3 apuntan en la misma dirección, aunque *verifica_identidad* queda al límite de la significancia (0,059) y se reporta como señal, no como conclusión.

Qué logra cada agente (variables semánticas).

	Humanos	IA	Dif.	<i>p</i>
Cierra compromiso de pago firme	56 %	25 %	−32 pp	0,002
Llamada termina sin ningún desenlace	4 %	45 %	+41 pp	<0,001
Deja claro cómo, cuándo y dónde pagar	56 %	20 %	−36 pp	<0,001
Concede algo concreto ante la objeción	59 %	32 %	−27 pp	0,024
El deudor objeta por desconfianza	10 %	29 %	+18 pp	0,039
Tono cordial	92 %	41 %	−51 pp	<0,001

Nota: “Concede algo concreto ante la objeción” se calcula solo sobre las llamadas donde hubo objeción; incluir las demás confundiría “no concedió” con “no tuvo nada que conceder”.

Robustez. Restringiendo el análisis a las llamadas donde el LLM declaró confianza alta, la brecha central no se debilita, se amplía: 72 % de compromisos firmes en humanos frente a 19 % en IA ($p < 0,001$). El hallazgo no vive de las etiquetas dudosas.

8. Hallazgos clave

1. **La IA cierra la mitad que un humano.** Logra compromiso de pago firme en 25 % de sus llamadas frente al 56 % de los humanos: 32 puntos porcentuales de diferencia.
2. **El problema no es que la IA cierre mal, es que no cierra.** El 45 % de sus llamadas termina sin ningún desenlace, contra el 4 % de las humanas (+41 pp). Es la brecha más grande del análisis y explica casi toda la diferencia de efectividad.
3. **Cuando la IA sí acuerda, el dinero se queda sin ruta.** Solo el 20 % de sus llamadas deja claro cómo, cuándo y dónde pagar, frente al 56 % de las humanas (−36 pp). Un acuerdo sin mecanismo de pago no se convierte en recaudo.
4. **La IA no negocia: repite.** Ante una objeción del deudor, el humano responde con algo concreto — nueva fecha, nuevo monto, plan de cuotas — en 59 % de los casos; la IA en 32 % (−27 pp). Sustituye esa flexibilidad por presión: menciona consecuencias legales o urgencia en 80 % de sus llamadas contra 33 % de las humanas.
5. **Y esa presión le cuesta credibilidad.** La objeción “no reconozco esta deuda / quién me llama” aparece en 29 % de las llamadas de IA frente al 10 % de las humanas (+18 pp): el guion de amenaza legal genera desconfianza en vez de urgencia.

6. **La IA responde siete veces más lento.** 1,87 s de silencio antes de cada respuesta contra 0,27 s del humano. El deudor percibe una conversación que no fluye, y es la explicación más probable de tantas llamadas sin desenlace.
7. **Lo que la IA hace mejor: cumplir y dejarse auditar.** Se identifica en la apertura en 80 % de las llamadas (humanos, 60 %) y verifica la identidad del interlocutor en 47 % (humanos, 27 %). Además, el 100 % de sus llamadas es auditable de forma automática, frente al 71 % de las humanas: nunca deja de cumplir el protocolo por cansancio o por prisa.

9. Conducta y qué tendría que cambiar

Lo que hacen mejor los humanos. Aterrizan la operación: cierran con monto, fecha y canal de pago concretos. Negocian de verdad — mueven la fecha o parten la cuota cuando el deudor dice que no puede — y sostienen un tono cordial (92 % de las llamadas) que mantiene al deudor en la conversación.

Lo que hace mejor la IA. Consistencia de protocolo y trazabilidad: se identifica, verifica identidad y deja un registro perfectamente auditable en el 100 % de los casos. No tiene días malos.

Las tres palancas para acercar los resultados, ordenadas por relación entre impacto y esfuerzo:

1. **Cerrar siempre con mecanismo de pago.** Antes de terminar, la IA debería enunciar monto, fecha y canal. Es la corrección más barata — una regla de cierre obligatoria en el guion — sobre la brecha de 36 pp que hoy separa el acuerdo del recaudo.
2. **Reducir la latencia.** Bajar el silencio de respuesta de 1,87 s a menos de 1 s atacaría directamente el 45 % de llamadas que hoy mueren sin desenlace.
3. **Cambiar presión por flexibilidad.** Menos amenaza legal — que hoy dispara la desconfianza — y más capacidad de mover fecha y monto ante la primera objeción, que es justamente donde el humano gana.

10. Limitaciones y error asumido

La transcripción falla en tramos con ruido de fondo, personas que contestan alejadas del teléfono o que hablan muy rápido: aparecen palabras sin sentido o fragmentos inconexos. Es más frecuente en las llamadas humanas, donde el canal es más ruidoso y variable que en las de IA.

La diarización falló de forma marcadamente distinta entre los dos grupos: en humanos el error es mucho mayor (32 % con un solo hablante) que en IA (2 %). La voz sintética de la IA tiene timbre y volumen constantes, lo que genera un *embedding* fácil de distinguir del interlocutor humano; en cambio, dos voces humanas comparten canal telefónico, acento y rango vocal similares, lo que dificulta separarlas. Este error asimétrico es en sí mismo un resultado (H4), pero también obliga a una cautela: por eso H1 se reporta además sobre el subconjunto de diarización limpia, donde se sostiene.

Las variables semánticas dependen del juicio de un LLM y no de un cálculo determinístico. Se mitiga con dos controles — validación de que no invente categorías, y repetición del contraste central solo sobre las etiquetas de confianza alta — pero el sesgo del modelo no se elimina del todo. Finalmente, con $n \approx 50$ por grupo, los contrastes tienen potencia para detectar diferencias grandes como las reportadas, no diferencias finas.

Asumimos este error, que no es sencillo de eliminar por completo: los modelos usados (`Whisper large-v3`, `pyannote.audio`) representan el estado del arte disponible en código abierto para este tipo de tareas.